

IA Autónoma con Agentes Empresariales

Trabajo de Investigación — Optativa Ciberseguridad

Alumno: Antonio Valero Maldonado

Curso: DAW2

Fecha: Mayo 2026

PARTE I — Investigación

1. Definición técnica de la tecnología

Para hablar de esto hay que partir de algo que ya conocemos todos: los chatbots del estilo de ChatGPT. Básicamente escribes algo y el modelo te contesta. Eso ya lo tenemos más o menos claro. Pero los agentes empresariales autónomos van bastante más allá, y creo que es importante entender la diferencia porque, si no, se confunde todo.

Un agente autónomo no espera a que le preguntes algo. Tiene un objetivo asignado y él solo va encadenando pasos para cumplirlo: revisa correos entrantes, accede a bases de datos, toma decisiones y ejecuta acciones reales sin que una persona tenga que ir indicándole cada paso. Esa es la gran diferencia respecto a un chatbot tradicional.

Por dentro, estos sistemas se apoyan en modelos de lenguaje grandes que ya conocemos, como GPT-4o, Gemini o Claude, pero añaden una capa extra llamada “bucle de razonamiento”. Gracias a ello, el agente puede planificar tareas, utilizar herramientas externas como APIs o bases de datos y, si algo falla, replantear la estrategia y probar otra solución.

A esta forma de funcionar se le conoce como *arquitectura agentic*, y es la que permite que el agente no se bloquee ante el primer problema.

Actualmente existen varios frameworks para desarrollar este tipo de sistemas. Entre los más conocidos destacan LangGraph, AutoGen, CrewAI y Agentforce. Todos funcionan de manera similar: el agente recibe una tarea, la divide en subtareas, las ejecuta y mantiene memoria del contexto y de las acciones realizadas.

Algo especialmente importante, y muy relacionado con la ciberseguridad, es que estos agentes no “simulan” acciones. Cuando se conectan al correo empresarial, al CRM o a sistemas financieros, actúan de verdad: crean, modifican, envían o eliminan información. Y eso tiene implicaciones enormes, tanto positivas como negativas.

2. Cómo puede afectar esta tecnología a una empresa

Cuando empecé a investigar este tema pensaba que el impacto principal estaría relacionado únicamente con el ahorro de tiempo en tareas pequeñas. Sin embargo, la realidad es mucho más profunda.

Diversos estudios de 2024 indican que entre el 60% y el 70% de las tareas realizadas por trabajadores del conocimiento —como administrativos, analistas o personal de soporte— podrían automatizarse en las próximas décadas. Esto supone un cambio enorme en la estructura de las empresas.

En atención al cliente ya se está viendo claramente. Herramientas como Salesforce Agentforce permiten resolver gran parte de las consultas sin intervención humana. Estos agentes no solo responden preguntas básicas, sino que pueden consultar historiales de clientes, verificar pedidos, gestionar reembolsos y enviar confirmaciones automáticamente.

Para pequeñas y medianas empresas esto supone una reducción importante de costes y una mejora notable en la velocidad de respuesta.

En el área financiera también aparecen ventajas relevantes. Los agentes conectados a plataformas como SAP o QuickBooks pueden revisar facturas, comprobar pedidos, validar pagos y detectar irregularidades automáticamente. Esto reduce errores humanos y acelera procesos que antes tardaban días.

Sin embargo, el ámbito donde más impacto tiene esta tecnología, especialmente desde el punto de vista de este módulo, es la ciberseguridad.

Los agentes autónomos ya se utilizan para analizar logs, correlacionar alertas, generar reglas de firewall y responder a incidentes en tiempo real. Empresas como CrowdStrike, Palo Alto Networks y Microsoft han integrado este tipo de capacidades en plataformas SIEM y SOAR.

Pero el problema es que los mismos agentes también pueden utilizarse con fines ofensivos. Un agente malicioso puede automatizar el reconocimiento de una red, generar campañas de phishing personalizadas, explotar vulnerabilidades y exfiltrar datos sin necesidad de intervención humana constante.

En 2024 ya se documentaron ataques de este tipo contra infraestructuras empresariales, lo que demuestra que esta amenaza ya no pertenece a la ciencia ficción.

3. Cómo puede afectar esta tecnología al trabajo

Este apartado probablemente sea el más delicado, porque es donde la tecnología empieza a afectar directamente a las personas y al mercado laboral.

A diferencia de automatizaciones anteriores centradas en trabajo físico, esta vez hablamos de trabajo cognitivo: análisis de información, gestión administrativa, redacción de textos o soporte técnico.

Los perfiles más expuestos son los puestos junior y repetitivos: analistas de datos iniciales, soporte técnico de primer nivel, asistentes administrativos o personal de back office.

Algunos estudios indican que casi la mitad de las tareas de un analista junior podrían automatizarse mediante IA generativa. Empresas como Klarna ya han comunicado públicamente que gran parte de sus consultas de soporte son gestionadas por agentes de IA con niveles de satisfacción similares a los humanos.

En ciberseguridad ocurre algo parecido. Muchas tareas realizadas por analistas SOC de nivel 1 — monitorizar logs, clasificar alertas y responder a incidentes simples— son exactamente el tipo de trabajo repetitivo que un sistema SOAR automatizado puede realizar con facilidad.

Aun así, no todo es destrucción de empleo. También aparecen nuevos perfiles profesionales que hace pocos años ni existían:

- Diseñadores de agentes de IA
- Auditores de decisiones automatizadas
- Especialistas en seguridad de IA
- Ingenieros de automatización inteligente

El problema es que estos nuevos trabajos requieren conocimientos muy distintos, y la transición laboral puede ser complicada para muchas personas.

Según previsiones del Foro Económico Mundial, millones de empleos desaparecerán debido a la automatización, aunque también se crearán otros nuevos relacionados con la inteligencia artificial. El saldo global puede ser positivo, pero el proceso de adaptación será difícil y desigual.

PARTE II — Opinión

Opinión fundamentada acerca de las bondades de la tecnología en la empresa

Cuando empecé a investigar este tema tenía una visión bastante escéptica. Pensaba que había mucho marketing alrededor de la inteligencia artificial y que la realidad práctica estaba lejos de lo que prometían los titulares.

Sin embargo, cuanto más investigaba, más cambié de opinión, especialmente respecto a los agentes autónomos.

Lo que más me convence es la capacidad de democratizar recursos tecnológicos que antes solo podían permitirse las grandes empresas. Una pyme pequeña puede automatizar atención al cliente, contabilidad básica, generación de informes y monitorización de sistemas sin necesidad de contratar grandes equipos.

En ciberseguridad, la principal ventaja es la velocidad de respuesta. Un SOC humano puede tardar meses en detectar una brecha de seguridad y semanas adicionales en contenerla. Durante ese tiempo, el atacante puede moverse libremente por la red.

Un agente autónomo, en cambio, puede detectar comportamientos anómalos en tiempo real y responder en cuestión de minutos. Esto supone una diferencia enorme en términos de seguridad.

Además, los agentes no sufren fatiga, estrés ni distracciones. Un analista humano puede pasar por alto una alerta después de horas de trabajo continuo; un agente mantiene el mismo nivel de actividad constantemente.

Eso no significa que los agentes sean perfectos, pero muchos de sus errores son más fáciles de detectar y corregir que los errores humanos derivados del cansancio.

Opinión fundamentada acerca de la problemática de la tecnología en la empresa

A pesar de todas sus ventajas, esta tecnología también presenta riesgos importantes.

El primero que más me ha llamado la atención es el *prompt injection*. Si un agente tiene acceso a correos, documentos o contenido externo, un atacante puede introducir instrucciones ocultas para manipularlo.

Por ejemplo, un email aparentemente normal podría contener instrucciones invisibles destinadas al agente, haciendo que este reenvíe información confidencial o ejecute acciones no autorizadas.

Este tipo de ataques ya existe y representa uno de los mayores desafíos actuales de seguridad en sistemas basados en IA.

Otro problema importante es la opacidad de los modelos de lenguaje. Muchas veces resulta difícil explicar exactamente por qué un agente tomó una determinada decisión. Esto puede generar conflictos legales en sectores como banca, seguros o sanidad, donde las decisiones automatizadas deben ser auditables y justificables.

También preocupa la concentración excesiva de poder. Cuanta más autonomía y acceso tenga un agente a sistemas críticos, mayor será el daño potencial si algo falla o si el sistema es comprometido por un atacante.

Un agente conectado a sistemas financieros o administrativos puede causar daños enormes en pocos minutos si recibe instrucciones erróneas o maliciosas.

Por último, está el impacto laboral. Aunque la tecnología también crea nuevas oportunidades, es evidente que muchos puestos están desapareciendo ya mismo, y muchas empresas no están gestionando adecuadamente esa transición.

Conclusión personal

Después de investigar este tema, la conclusión a la que llego es que los agentes autónomos basados en IA no son una moda pasajera. Son una tecnología que ya está transformando el funcionamiento de empresas reales y que seguirá creciendo rápidamente en los próximos años.

Lo que más me preocupa no es la tecnología en sí, sino la velocidad a la que se está implantando comparada con la velocidad a la que se está regulando y asegurando.

Muchas empresas están desplegando agentes con acceso a sistemas críticos sin definir claramente qué pueden hacer, sin trazabilidad adecuada y sin planes de contingencia si algo falla.

Desde el punto de vista de la ciberseguridad, eso representa un riesgo enorme.

La verdadera pregunta ya no es si las empresas deberían usar agentes de IA, porque probablemente la mayoría acabará haciéndolo. La cuestión importante es cómo hacerlo de forma segura, con controles adecuados, supervisión, auditoría y límites claros.

Y precisamente para poder diseñar y exigir esas medidas de seguridad, es fundamental entender cómo funcionan estos sistemas y cuáles son sus riesgos reales.

Antonio Valero Maldonado

Optativa Ciberseguridad — DAW2 — Mayo 2026