

IA Autónoma con Agentes Empresariales

Trabajo de Investigación — Optativa Ciberseguridad

Alumno: Antonio Valero Maldonado

Curso: DAW2

Fecha: Mayo 2026

PARTE I — Investigación

1. Definición técnica de la tecnología

Para entender qué son los agentes autónomos empresariales, primero hay que compararlos con algo que ya usamos casi todos: los chatbots tipo [ChatGPT](#).

Un chatbot normal funciona de forma bastante simple: tú escribes una pregunta y el sistema responde. Todo depende de que una persona le vaya diciendo qué hacer en cada momento.

Los agentes autónomos funcionan de otra manera. En vez de esperar instrucciones constantemente, reciben un objetivo y trabajan por su cuenta para intentar cumplirlo. Por ejemplo, un agente puede encargarse de revisar correos, consultar bases de datos, organizar información o incluso ejecutar acciones dentro de sistemas de empresa sin que alguien tenga que supervisar cada paso.

La diferencia importante está en que el agente puede “pensar” qué hacer después. Si algo falla, intenta buscar otra solución.

Esto se consigue gracias a una arquitectura llamada *agentic*, que combina modelos de lenguaje con herramientas externas y un sistema de razonamiento continuo.

Actualmente, los modelos más conocidos que sirven de base para estos agentes son GPT-4o, Gemini o Claude.

Encima de esos modelos se utilizan frameworks especializados como LangGraph, AutoGen, CrewAI o Agentforce.

Todos estos sistemas siguen una idea parecida:

1. El agente recibe una tarea.
2. Divide esa tarea en partes más pequeñas.
3. Usa herramientas externas si lo necesita.
4. Guarda memoria del proceso.
5. Toma decisiones según los resultados obtenidos.

Lo más importante es que estos agentes no solo “hablan” como un chatbot. Cuando tienen acceso a programas reales de empresa pueden actuar de verdad: enviar emails, modificar datos, aprobar procesos o acceder a información sensible. Y ahí es donde empiezan muchos de los riesgos relacionados con la ciberseguridad.

2. Cómo puede afectar esta tecnología a una empresa

Cuando empecé a investigar este tema pensaba que el impacto de esta tecnología se limitaba sobre todo a ahorrar tiempo en tareas pequeñas. Pero viendo ejemplos reales me di cuenta de que el cambio puede ser muchísimo mayor.

Actualmente muchas empresas están empezando a usar agentes autónomos para automatizar tareas que antes hacían personas.

En atención al cliente, por ejemplo, algunos agentes ya pueden responder consultas, revisar pedidos, gestionar devoluciones o enviar confirmaciones automáticamente sin necesidad de que intervenga un trabajador humano.

Esto tiene ventajas claras para las empresas:

- reducción de costes,
- respuestas más rápidas,
- disponibilidad constante,
- y menos carga de trabajo repetitiva.

En el área financiera también se están usando bastante. Un agente conectado a programas de contabilidad puede revisar facturas, comprobar pagos o detectar errores automáticamente. Eso acelera muchísimo procesos administrativos que antes llevaban bastante tiempo.

Pero donde más me llamó la atención fue en el campo de la ciberseguridad.

Muchas empresas están integrando agentes de IA en plataformas de monitorización y defensa. Estos sistemas pueden analizar logs, detectar comportamientos extraños o responder automáticamente ante ciertos ataques.

Empresas como CrowdStrike, Microsoft Security o Palo Alto Networks ya trabajan con tecnologías similares dentro de herramientas SIEM y SOAR.

El problema es que esta misma tecnología también puede utilizarse para atacar.

Un agente malicioso podría automatizar tareas ofensivas como:

- escanear redes,
- buscar vulnerabilidades,
- crear campañas de phishing más personalizadas,
- o robar información automáticamente.

Y eso es preocupante porque hace que ciertos ataques sean más rápidos y más difíciles de detectar.

3. Cómo puede afectar esta tecnología al trabajo

Creo que esta parte es probablemente la más delicada porque afecta directamente al empleo y a muchas profesiones actuales.

A diferencia de otras automatizaciones antiguas que sustituían trabajo físico, esta vez la IA afecta sobre todo a tareas cognitivas: análisis de información, gestión administrativa, soporte técnico o redacción de contenido.

Los puestos más expuestos suelen ser los más repetitivos o de nivel inicial.

Por ejemplo:

- soporte técnico básico,
- atención al cliente,
- tareas administrativas,
- análisis de datos sencillos,
- o ciertos trabajos de back office.

Muchas empresas ya están usando IA para reducir parte de ese trabajo. Un ejemplo bastante conocido es [Klarna](#), que comentó públicamente que gran parte de su soporte ya estaba siendo gestionado por sistemas de inteligencia artificial.

En ciberseguridad también ocurre algo parecido.

Las tareas típicas de un analista SOC junior —como revisar alertas simples o clasificar eventos— son precisamente el tipo de trabajo repetitivo que un sistema automatizado puede hacer bastante bien.

Aun así, no todo es negativo.

También están apareciendo nuevos perfiles profesionales relacionados con esta tecnología:

- diseñadores de agentes IA,
- especialistas en automatización,
- auditores de decisiones automatizadas,
- expertos en seguridad de IA,
- o ingenieros de integración.

El problema es que la transición no será fácil para todo el mundo. Muchas personas tendrán que aprender habilidades nuevas para adaptarse a este cambio tecnológico.

PARTE II — Opinión

Opinión sobre las ventajas de esta tecnología en la empresa

Antes de investigar este tema tenía bastante desconfianza con todo lo relacionado con IA. Pensaba que muchas veces se exageraban sus capacidades y que había bastante marketing detrás.

Pero después de leer casos reales y ver cómo funcionan estos sistemas, cambié bastante de opinión.

Lo que más interesante me parece es que tecnologías que antes solo podían permitirse empresas enormes ahora también están al alcance de pequeñas empresas.

Una pyme puede automatizar tareas de atención al cliente, informes o monitorización sin necesidad de contratar equipos muy grandes.

En ciberseguridad creo que la mayor ventaja es la velocidad.

Muchas veces un ataque tarda semanas o meses en detectarse porque los equipos humanos no dan abasto. Un agente autónomo puede revisar actividad constantemente y reaccionar en tiempo real.

También hay que reconocer que un sistema automatizado no se cansa.

Una persona después de muchas horas trabajando puede cometer errores o pasar por alto alertas importantes. Un agente mantiene el mismo ritmo continuamente.

Obviamente no son perfectos, pero bien configurados pueden ser una ayuda enorme para reducir trabajo repetitivo y mejorar tiempos de respuesta.

Opinión sobre los problemas y riesgos de esta tecnología

Aunque tiene ventajas claras, también me parece una tecnología bastante peligrosa si se usa sin control.

Uno de los riesgos que más me llamó la atención es el *prompt injection*.

Básicamente consiste en engañar al agente mediante instrucciones ocultas dentro de correos, documentos o páginas web.

Por ejemplo, un atacante podría enviar un email aparentemente normal pero con instrucciones escondidas dirigidas a la IA para hacer que el agente filtre información o ejecute acciones no autorizadas.

Otro problema importante es que muchas veces ni siquiera los desarrolladores pueden explicar exactamente por qué la IA tomó una decisión concreta.

Eso puede generar problemas legales importantes en sectores donde las decisiones deben justificarse claramente, como banca o sanidad.

También me preocupa el exceso de autonomía.

Cuanto más acceso tenga un agente a sistemas críticos, mayor puede ser el daño si ocurre un fallo o si alguien consigue comprometerlo.

Un agente conectado a sistemas financieros o administrativos podría provocar problemas enormes en pocos minutos si actúa incorrectamente.

Y obviamente está el tema laboral.

Aunque aparecerán nuevos trabajos, también es evidente que muchos puestos actuales van a desaparecer o cambiar muchísimo en relativamente poco tiempo.

Conclusión personal

Después de investigar este tema creo que los agentes autónomos basados en IA no son una moda temporal. Todo apunta a que van a formar parte del funcionamiento normal de muchísimas empresas en los próximos años.

Lo que más me preocupa no es tanto la tecnología en sí, sino la rapidez con la que se está implantando comparada con la velocidad a la que se están creando medidas de seguridad y regulaciones.

Muchas empresas están dando acceso a sistemas críticos a agentes de IA sin tener todavía controles claros, auditorías completas o planes preparados por si algo falla.

Desde el punto de vista de la ciberseguridad, eso puede convertirse en un problema bastante serio.

Al final, la pregunta ya no es si las empresas van a usar agentes de IA, porque probablemente casi todas terminarán utilizándolos de alguna forma.

La verdadera cuestión es cómo hacerlo de forma segura, con límites claros y supervisión humana adecuada.

Y precisamente por eso creo que es importante entender bien cómo funcionan estos sistemas y qué riesgos reales tienen.

Antonio Valero Maldonado

Optativa Ciberseguridad — DAW2 — Mayo 2026